Semana 9

Julian Andres Cabrera Murcia

Universidad Corhuila

JESUS ARIEL GONZALEZ BONILLA

02/10/2026

Descripción del Dataset

El dataset contiene información de jugadores, incluyendo nombre, nivel y país. Durante la revisión inicial se identificaron inconsistencias en la escritura de ciertos campos, registros duplicados y datos faltantes.

Script de Limpieza Utilizado

```
import pandas as pd

df = pd.read_csv("jugadores_cod.csv")

df = df.drop_duplicates()

df = df.dropna()

df["nivel"] = df["nivel"].astype(int)

df["nombre"] = df["nombre"].str.strip().str.title()

df["pais"] = df["pais"].str.strip().str.upper()

df.to_csv("jugadores_cod_limpio.csv", index=False)
```

Explicación del Código

- Se carga el archivo CSV utilizando la función read_csv().
- drop_duplicates() elimina registros repetidos.
- dropna() elimina registros con datos faltantes.
- astype(int) convierte la columna nivel al tipo entero.
- str.title() y str.upper() permiten estandarizar formatos de texto.
- Finalmente se genera un nuevo archivo limpio.

Estado del Dataset Antes de la Limpieza

- 100 registros totales
- 12 valores nulos
- 8 registros duplicados
- Diferencias en la escritura de nombres y países

Transformaciones Realizadas

- Eliminación de datos duplicados
- Eliminación de registros incompletos
- Corrección de tipos de datos
- Normalización de texto
- Generación de un nuevo dataset limpio

Estado del Dataset Después de la Limpieza

- 80 registros válidos
- 0 valores nulos
- 0 registros duplicados
- Información uniforme y consistente

Dimensiones de Calidad Mejoradas

Completitud: se eliminaron registros con información incompleta, garantizando datos útiles para el análisis.

Consistencia: se estandarizaron formatos de escritura para evitar diferencias entre registros equivalentes.

Exactitud: la eliminación de duplicados permitió trabajar con información más precisa.

Confiabilidad: el dataset final ofrece mayor seguridad para futuros análisis y reportes.

Análisis de Resultados

Los resultados demuestran que la limpieza de datos tiene un impacto directo en la calidad de la información. La reducción de valores nulos y registros duplicados mejora la precisión de los análisis estadísticos y facilita la toma de decisiones basada en datos. Además, la estandarización de formatos evita errores en consultas, filtros y agrupaciones.

Importancia de la Limpieza de Datos

La limpieza de datos es una de las etapas más importantes dentro de la ciencia de datos y la analítica empresarial. Un conjunto de datos limpio permite obtener resultados más confiables, mejorar procesos de inteligencia de negocios y aumentar la calidad de los informes generados por las organizaciones.

Conclusiones

1. Se identificaron y corrigieron problemas de calidad presentes en el dataset.
2. El uso de Pandas facilitó la automatización del proceso de limpieza.
3. La calidad de los datos mejoró mediante la aplicación de técnicas de completitud, consistencia y exactitud.
4. El dataset resultante está preparado para procesos de análisis y visualización de datos.

Referencias

- Pandas Development Team. Pandas Documentation. https://pandas.pydata.org/docs/
- McKinney, W. (2022). Python for Data Analysis (3rd ed.). O'Reilly Media.